Virtualisation (CPU) : ordonnancement

Thibaud Martinez
thibaud.martinez@dauphine.psl.eu

Dauphine | PSL
UNIVERSITÉ PARIS

Cette présentation couvre les chapitres 6, 7 et 8 de Operating Systems: Three Easy Pieces.

Les diapositives sont librement inspirées de diapositives de *Youjip Won (Hanyang University)* et *Mathias Payer (EPFL)*.

Comment virtualiser efficacement le processeur tout en gardant le contrôle ?

→ Le système d'exploitation doit partager le processeur en *timesharing*.

Problèmes :

- **Performance** : comment mettre en œuvre la virtualisation sans ajouter une surcharge excessive au système ?
- **Contrôle** : comment exécuter des processus de manière efficace tout en gardant le contrôle du CPU ?

Exécution directe

Pour une exécution performante, il suffit d'**exécuter le programme directement sur le CPU**.

Problème : par définition, lorsque le programme est exécuté sur le processeur, le noyau ne l'est pas. **Il faut limiter l'exécution des programmes utilisateur**. Sans limites, le système d'exploitation ne contrôlerait rien.

Solution : exécution directe limitée

Deux modes d'exécution sont supportés par le processeur :

- **Mode utilisateur** : les programmes n'ont pas un accès complet aux ressources matérielles.
- **Mode noyau** : le système d'exploitation a accès à l'ensemble des ressources de la machine.

Un bit, appelé **bit de mode**, est présent dans le processeur pour indiquer le mode actuel : noyau (0) ou utilisateur (1).

Problème : opérations restreintes

Que faire si un processus souhaite effectuer une opération restreinte comme :

- envoyer une requête d'écriture à un disque;
- obtenir l'accès à plus de ressources système telles que le CPU ou la mémoire ?

Solution : appels systèmes (*system calls*)

Permettent au noyau d'exposer des services au programme qui s'exécute en mode utilisateur :

- accéder au système de fichiers;
- créer et détruire des processus;
- communiquer avec d'autres processus;
- allouer de la mémoire supplémentaire...

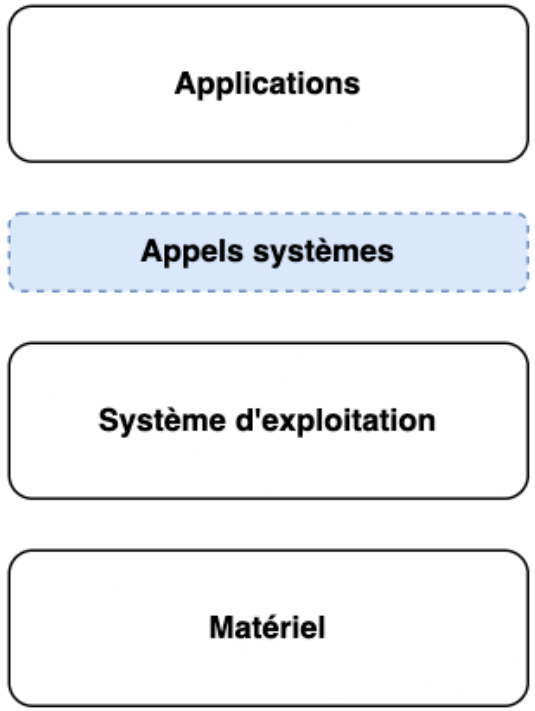

Appels systèmes

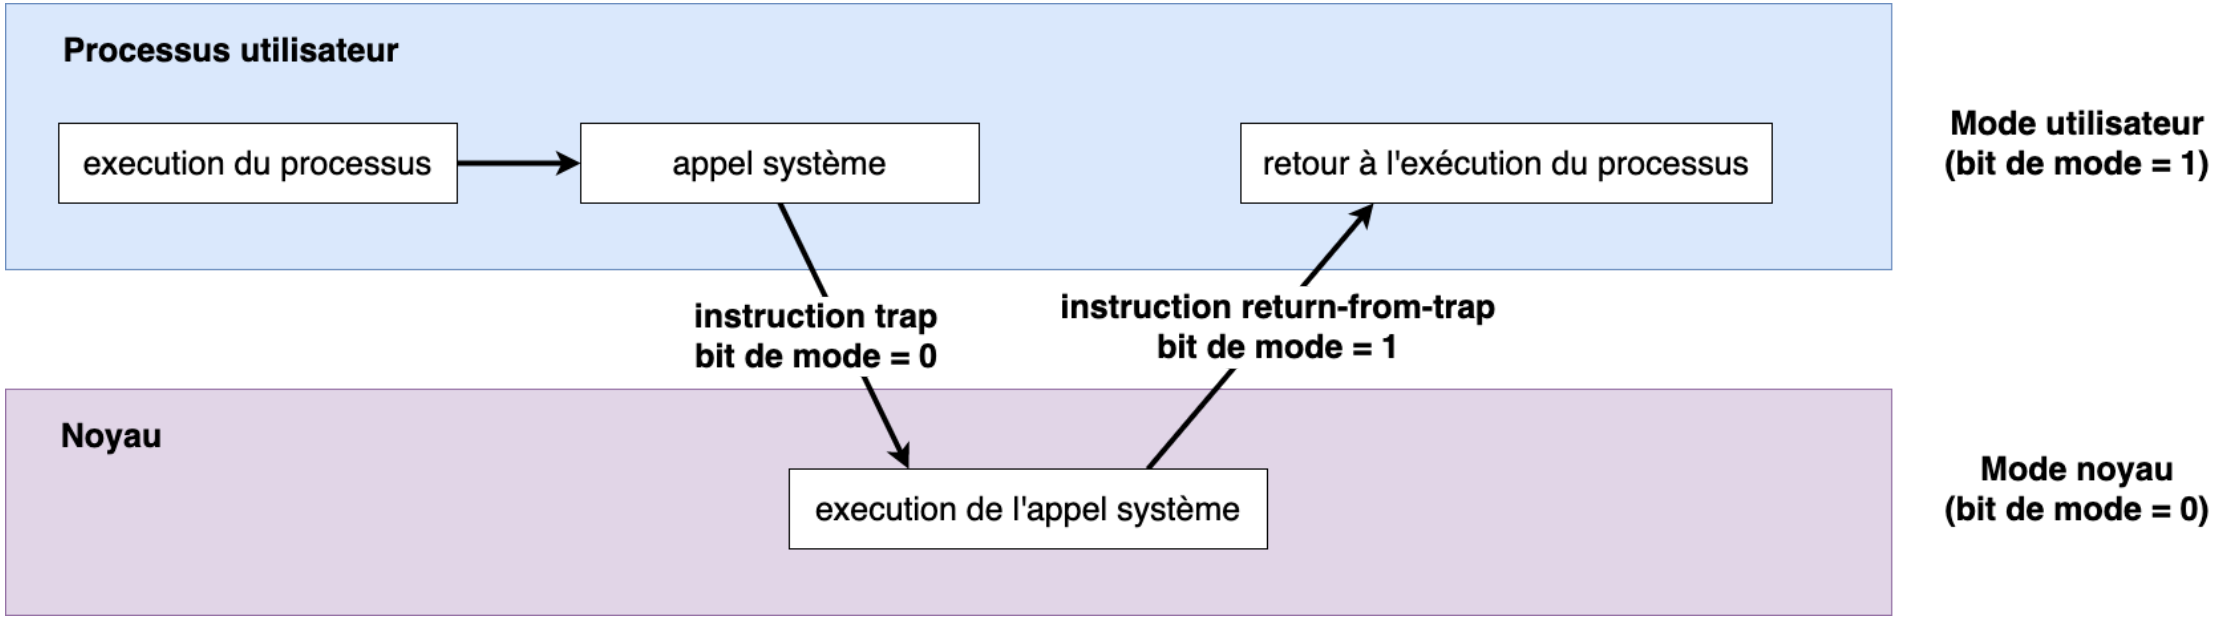

Remarque : Sur les processeurs x86, l'instruction trap s'appelle `INT`.

Problème : passage d'un processus à l'autre

Comment le système d'exploitation peut-il reprendre le contrôle du processeur afin de pouvoir passer d'un processus à l'autre ?

Solution 1 : une approche coopérative

- **Les processus abandonnent périodiquement le processeur** en effectuant des appels système tels que `yield`.
- Les processus transfèrent également le contrôle au système d'exploitation lorsqu'ils font quelque chose d'illégal, tels que :
    - diviser par zéro;
    - essayer d'accéder à une zone mémoire à laquelle ils ne devraient pas pouvoir accéder.

Problème : un processus peut rester coincé dans une boucle infinie et vous devez redémarrer la machine.

Solution 2 : une approche non coopérative

Pendant la séquence de démarrage, le système d'exploitation lance une minuterie. **La minuterie génère une interruption toutes les quelques millisecondes**.

Quand une interruption se produit :

- Le processus en cours d'exécution est arrêté.
- L'état du programme est sauvegardé.
- Un gestionnaire d'interruption préconfiguré dans le système d'exploitation s'exécute.

Une interruption de minuterie donne au noyau la possibilité de s'exécuter à nouveau sur le processeur.

Sauvegarde et restauration du contexte

Lors d'une interruption du processus utilisateur (volontaire ou non), l'ordonnanceur prend une **décision** : continuer à exécuter le processus en cours, ou passer à un autre.

Si la décision de basculer est prise, le système d'exploitation effectue une **commutation de contexte**.

Commutation de contexte (*context switch*)

Une commutation de contexte est un mécanisme qui :

1. sauvegarde l'état du processus en cours (valeurs des registres notamment), dans une structure du noyau;
2. restaure l'état du processus à exécuter ensuite;
3. transfère le contrôle du processeur au processus suivant.

Remarque : une commutation de contexte est transparent pour le processus.

Raisons d'une commutation de contexte

- Le processus se termine.
- Le processus effectue une opération d'E/S lente et le système d'exploitation passe à une autre tâche qui est prête.
- Le matériel nécessite l'aide du système d'exploitation et émet une interruption.
- Le système d'exploitation décide de préempter le processus et de passer à une autre (c'est-à-dire que le processus a épuisé sa tranche de temps).

Politique d'ordonnancement

Bas niveau : le mécanisme de **commutation de contexte** s'occupe de la manière dont le noyau passe d'un processus à l'autre.

Haut niveau : la **politique d'ordonnancement** détermine quel processus doit être exécuté ensuite.

→ S'il n'y a qu'un seul processus "prêt", la réponse est simple. S'il y a plusieurs processus, la politique décide de l'ordre d'exécution des processus.

Mesures de l'ordonnanceur

- **Utilisation** : quelle fraction du temps le CPU exécute-t-il un programme ? (objectif : maximiser)
- **Temps de traitement (*turnaround time*)** : temps global total entre la création et l'aboutissement d'un processus. (objectif : minimiser)
- **Temps de réponse (*response time*)** : temps entre le moment où le processus est prêt et celui où il est ordonnancé (objectif : minimiser)
- **Équité (*fairness*)** : tous les processus obtiennent la même quantité de CPU au fil du temps (objectif : pas de famine).
- **Progrès** : permettre aux processus de progresser (objectif : minimiser les interruptions du noyau).

Rappel : états des processus

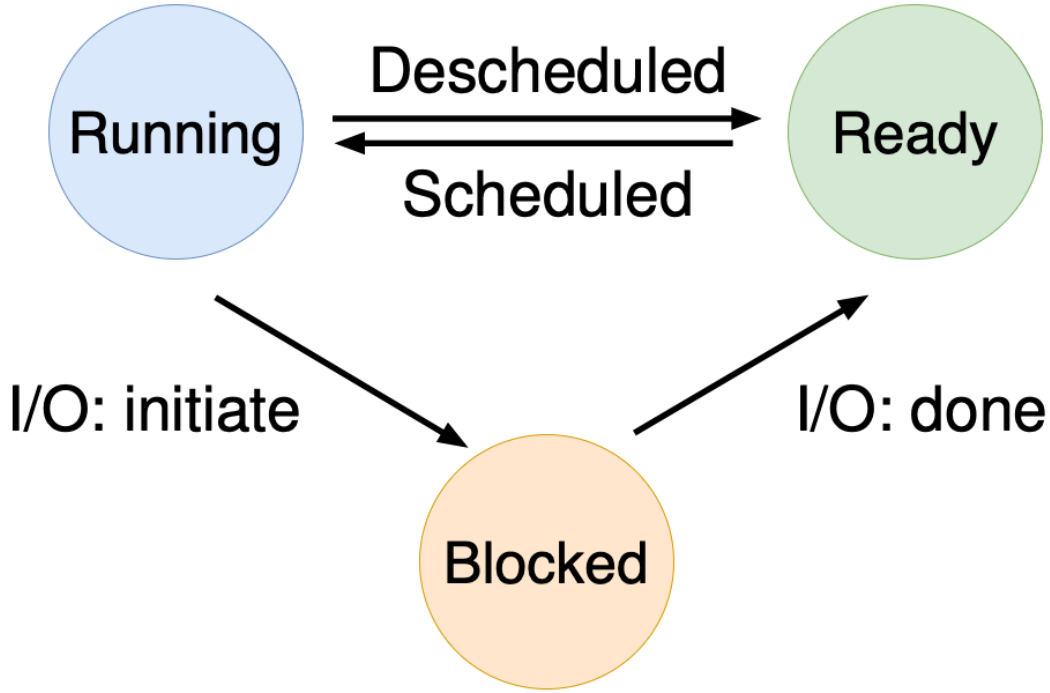

Hypothèses d'ordonnancement

- Chaque tâche est exécutée pendant la même durée.
- Toutes les tâches arrivent au même moment.
- Toutes les tâches n'utilisent que le CPU (pas d'E/S).
- Le temps d'exécution des tâches est connu.
- Un seul processeur.

First-in, first-out (FIFO)

- Les tâches A, B, C de `taille=2` arrivent à `T=0`.
- Temps de traitement moyen : `(2+4+6)/3 = 4`
- Temps de réponse moyen : `(0+2+4)/3 = 2`

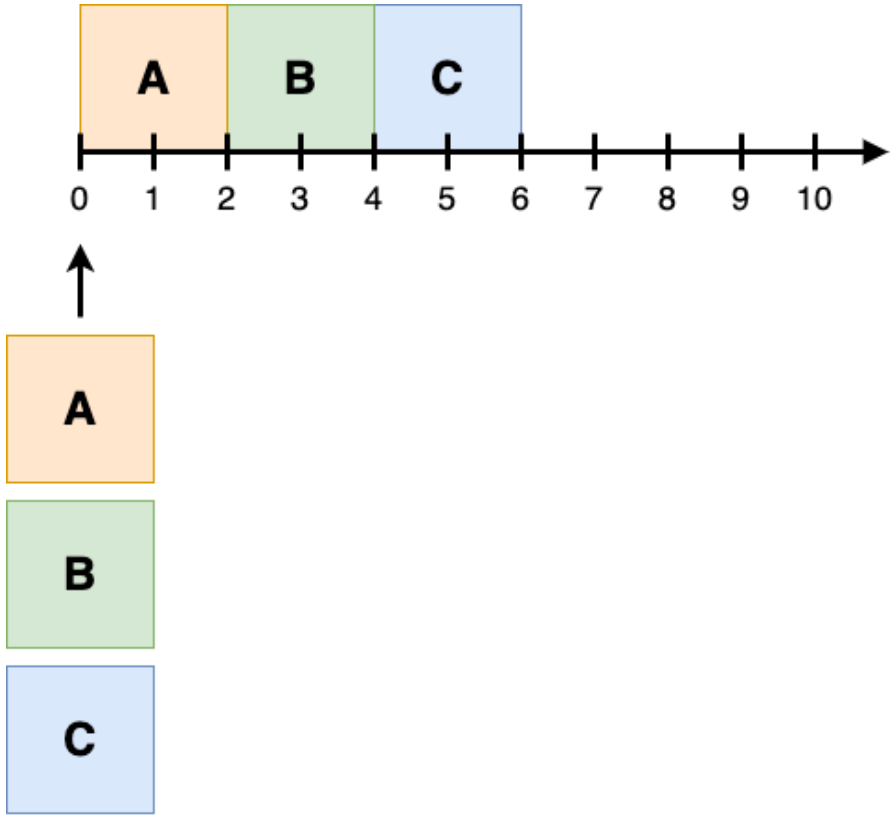

Constat : facile, simple, direct. Quels sont les inconvénients ?

Hypothèses d'ordonnancement

- ~~**Chaque tâche est exécutée pendant la même durée.**~~
- Toutes les tâches arrivent au même moment.
- Toutes les tâches n'utilisent que le CPU (pas d'E/S).
- Le temps d'exécution des tâches est connu.

Défi FIFO : tâche longue

- La tâche A est maintenant de `taille=6`.
- Temps de traitement moyen : `(6+8+10)/3 = 8`
- Temps de réponse moyen : `(0+6+8)/3 = 4.7`

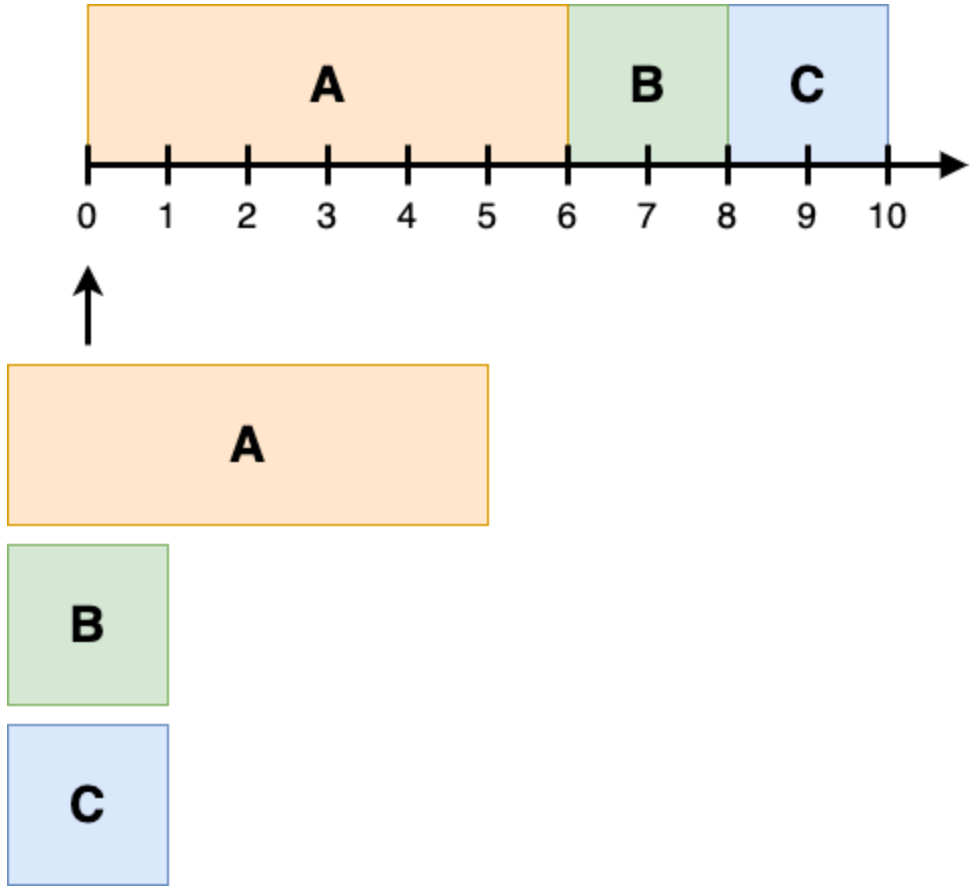

Constat : les tâches longues retardent les tâches courtes, les délais d'exécution/de réponse en souffrent !

Shortest job first (SJF)

Choisit la tâche prête avec le temps d'exécution le plus court.

- La tâche A est de `taille=6`.
- Temps de traitement moyen : `(2+4+10)/3 = 5.3`
- Temps de réponse moyen : `(0+2+4)/3 = 2`

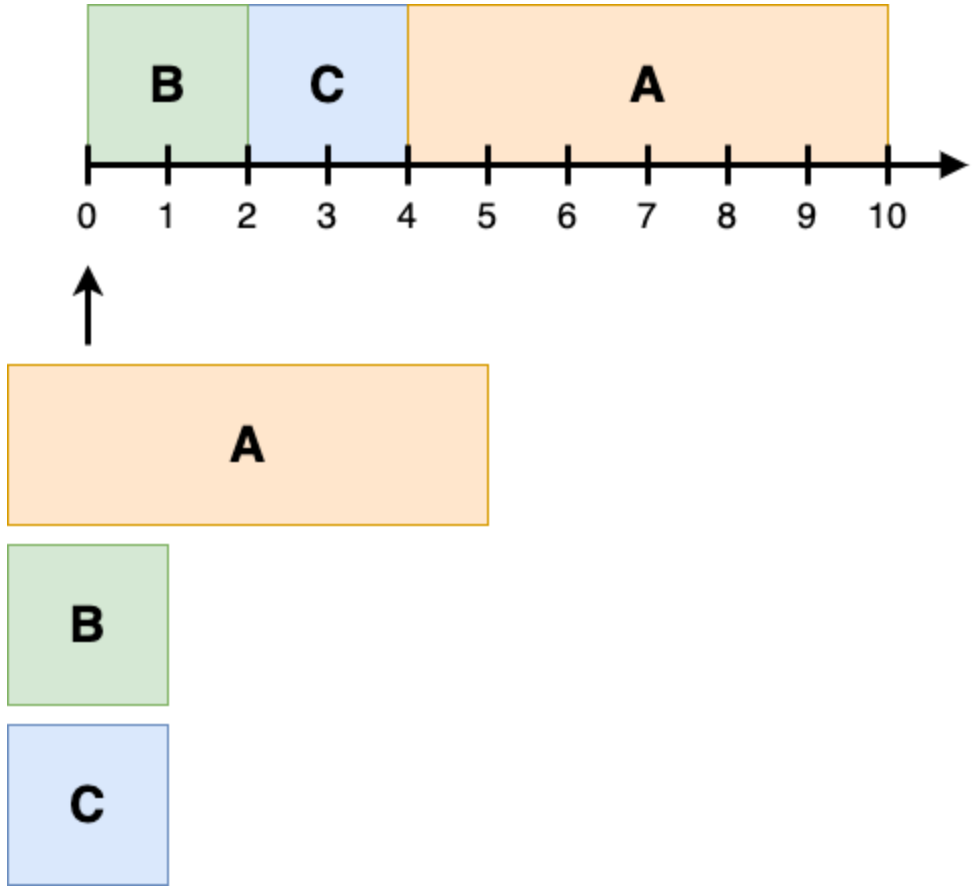

Hypothèses d'ordonnancement

- ~~Chaque tâche est exécutée pendant la même durée.~~
- ~~**Toutes les tâches arrivent au même moment.**~~
- Toutes les tâches n'utilisent que le CPU (pas d'E/S).
- Le temps d'exécution des tâches est connu.

SJF : une autre file de tâches

- Les tâches B et C arrivent maintenant à 1.
- Temps de traitement moyen : `(6+7+9)/3 = 7.3`
- Temps de réponse moyen : `(0+5+7)/3 = 4`

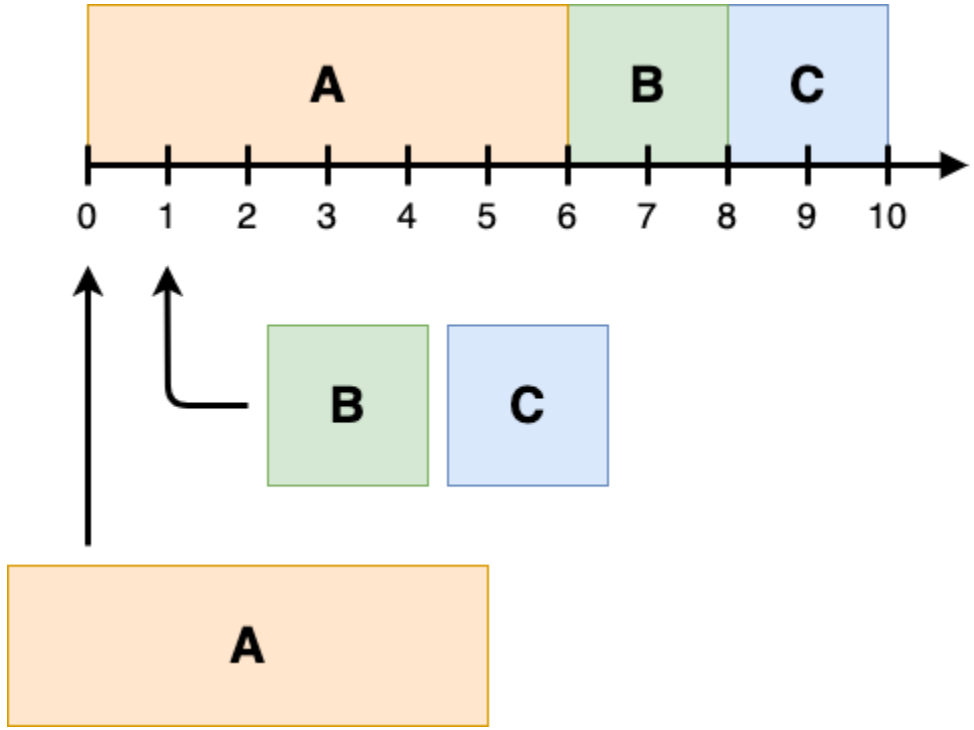

Constat : les tâches longues ne peuvent pas être interrompues et retardent les tâches courtes.

Ordonnancement préemptif

- Les ordonnanceurs précédents (FIFO, SJF) sont **non-préemptifs**. Les ordonnanceurs non-préemptifs ne passent à un autre processus que si le processus actuel abandonne le CPU volontairement.
- Les ordonnanceurs **préemptifs** peuvent prendre le contrôle du CPU à tout moment, en passant à un autre processus selon la politique d'ordonnancement.

Ordonnancement préemptif : STCF

Le STCF (*shortest time to completion first*), exécute toujours le travail qui se termine le plus rapidement.

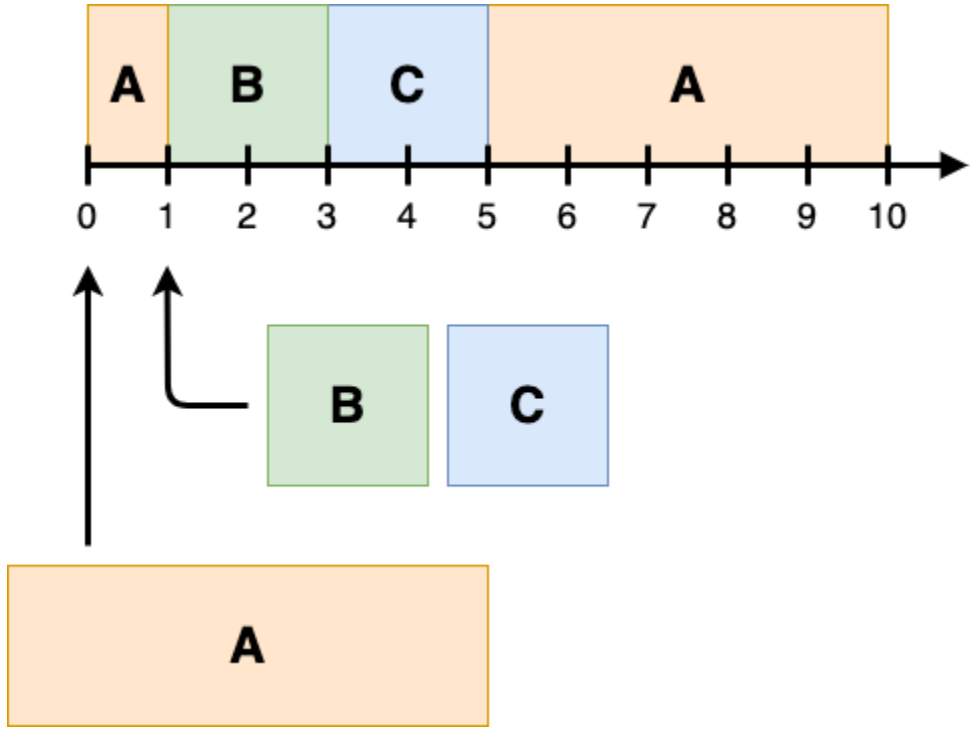

- Les tâches B et C arrivent à 1.
- Temps de traitement moyen : `(2+4+10)/3 = 5.3`
- Temps de réponse moyen : `(0+0+2)/3 = 0.7`

Constat : ré-ordonnancer à chaque fois que de nouvelles tâches arrivent donne la priorité aux tâches courtes.

Optimiser le temps de réponse

- Jusqu'à présent, nous avons optimisé le **temps de traitement** (c'est-à-dire l'accomplissement des tâches aussi vite que possible).
- Sur un système interactif, le **temps de réponse** (le temps qu'il faut pour qu'une tâche commence à être exécutée) est tout aussi important.

Round robin (RR)

Alterne les processus prêts chaque tranche de temps de longueur fixe.

- Tâches A, B, C `taille=3`, arrive à `T=0`
- Temps de reponse moyen :
  - `(0+1+2)/3 = 1` pour RR
  - `(0+3+6)/3 = 3` pour FIFO
- Temps de traitement moyen :
  - `(7+8+9)/3 = 8` pour RR
  - `(3+6+9)/3 = 6` pour SJF

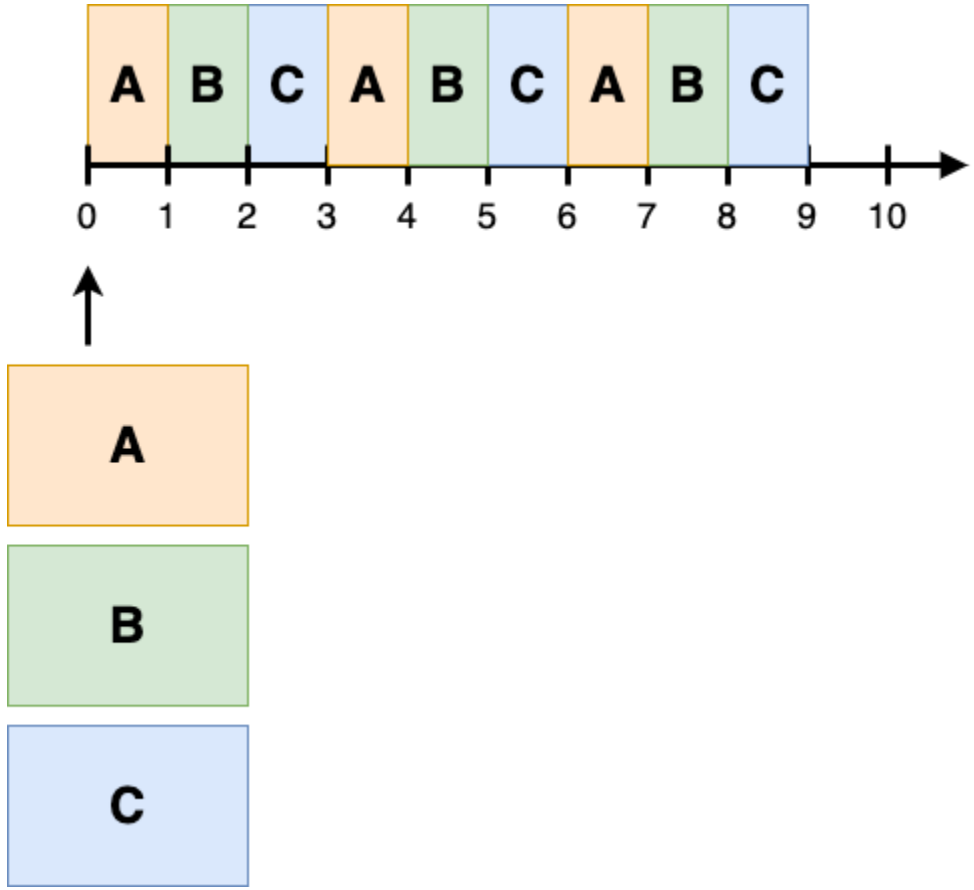

Constat : la réactivité augmente le délai d'exécution (pour des tâches de même durée).

Hypothèses d'ordonnancement

- ~~Chaque tâche est exécutée pendant la même durée.~~
- ~~Toutes les tâches arrivent au même moment.~~
- **~~Toutes les tâches n'utilisent que le CPU (pas d'E/S).~~**
- Le temps d'exécution des tâches est connu.

Conscience des E/S

- Jusqu'à présent, l'ordonnanceur ne prend en compte que les événements préemptifs (i.e., le minuteur s'arrête) ou la fin/création de processus pour replanifier.
- Les E/S sont généralement très lentes et peuvent être effectuées de manière asynchrone.

Constat : le ordonnanceur doit prendre en compte les E/S, le temps inutilisé sera ainsi utilisé par d'autres processus.

Hypothèses d'ordonnancement

- ~~Chaque tâche tourne pendant la même durée~~.
- ~~Toutes les tâches arrivent au même moment~~.
- ~~Tous les jobs n'utilisent que le CPU (pas d'E/S)~~
- ~~***Le temps d'exécution des jobs est connu***~~.

Multi-level feedback queue (MLFQ)

Défi : prendre en charge à la fois les tâches d'arrière-plan de longue durée et des tâches d'avant-plan à faible latence (processus interactifs).

Le MLFQ comporte des **files d'attente distinctes**, chacune avec un niveau de **priorité** différent.

- **Règle 1** : les tâches dans la file avec le niveau de priorité le plus haut, sont executées en priorité.
- **Règle 2** : plusieurs tâches peuvent avoir la même priorité, dans ce cas l'ordonnancement *round-robin* est utilisé entre ces tâches.

MLFQ : exemple

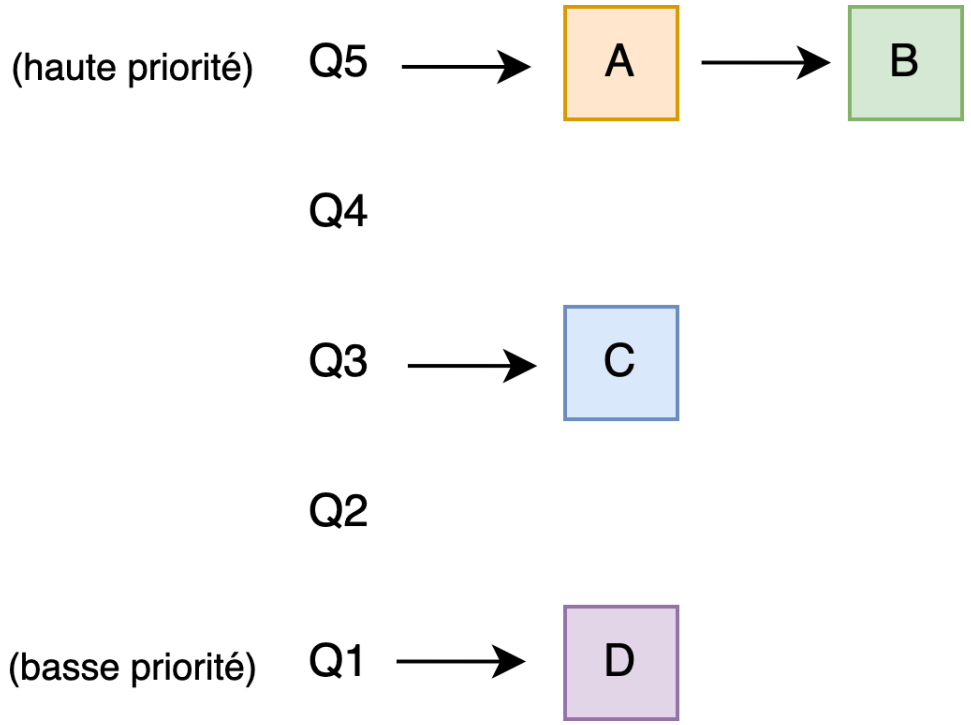

Comment ajuster les priorités ?

Plutôt que d'accorder une priorité fixe à chaque tâche, MLFQ fait varier la priorité d'une tâche en fonction de son comportement observé.

- **Règle 3** : les nouvelles tâches ont la priorité la plus élevée (la file d'attente la plus haute).
- **Règle 4a** : si une tâche utilise une tranche de temps entière pendant son exécution, sa priorité est réduite (c'est-à-dire qu'elle descend d'une file d'attente).
- **Règle 4b** : si une tâche abandonne le CPU avant la fin de la tranche de temps, elle reste au même niveau de priorité.

Comment gérer le risque de famine ?

Les tâches de faible priorité risquent de ne jamais être exécutées sur un système occupé.

- **Règle 5** : toutes les tâches sont déplacées périodiquement vers la file d'attente la plus prioritaire.

Comment gérer les processus qui tenteraient de tricher ?

Un processus de haute priorité pourrait céder le CPU avant que sa tranche de temps ne soit écoulée, restant ainsi en haute priorité.

→ *Il faut tenir compte du temps total d'exécution d'une tâche à un niveau de priorité donné*.

- **Règle 4** : lorsqu'une tâche a épuisé son temps alloué à un niveau donné (quel que soit le nombre de fois où elle a renoncé au CPU), sa priorité est réduite.

Le MLFQ en résumé

- **Règle 1** : les tâches dans la file avec le niveau de priorité le plus haut, sont executées en priorité.
- **Règle 2** : plusieurs tâches peuvent avoir la même priorité, dans ce cas l'ordonnancement *round-robin* est utilisé entre ces tâches.
- **Règle 3** : les nouvelles tâches ont la priorité la plus élevée.
- **Règle 4** : lorsqu'une tâche a épuisé son temps alloué à un niveau donné, sa priorité est réduite.
- **Règle 5** : toutes les tâches sont déplacées périodiquement vers la file d'attente la plus prioritaire.

Pour aller plus loin

- Sur le coût en termes de performance d'un *context switch* pour un serveur web : Ryan Dahl: Node JS (vidéo).
- Une approche d'ordonnancement qui essaye de garantir que chaque tâche obtienne un certain pourcentage de temps CPU : Scheduling: Proportional Share.
- L'ordonnanceur actuel de Linux : Inside the Linux 2.6 Completely Fair Scheduler.