Persistence : périphériques d'entrées-sorties

Thibaud Martinez
thibaud.martinez@dauphine.psl.eu

Dauphine | PSL
UNIVERSITÉ PARIS

Cette présentation couvre les chapitres 36 et 37 de Operating Systems: Three Easy Pieces.

Les diapositives sont librement adaptées de diapositives de *Youjip Won (Hanyang University)*.

Entrées-sorties (E/S)

- Imaginez un programme sans aucune entrée (il produit le même résultat à chaque fois).
- Imaginez un programme sans aucune sortie (quel était le but de son exécution ?)

→ **Les entrées-sorties sont essentielles pour les systèmes informatiques.**

Défis :

- Comment les E/S doivent-elles être intégrées dans les systèmes ?
- Quels sont les mécanismes généraux ?
- Comment les rendre efficaces ?

Architecture d'un système informatique

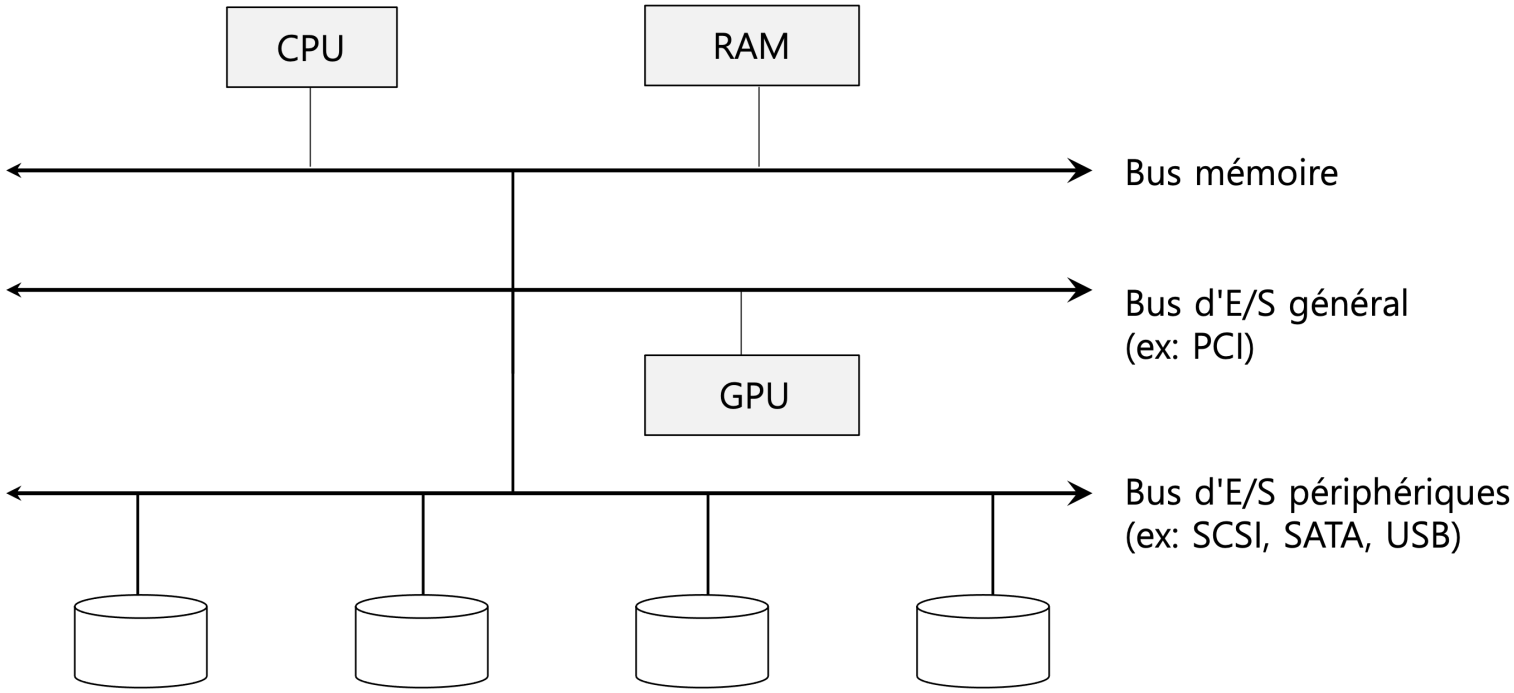

Architecture de système typique

Le processeur est reliée à la mémoire principale du système par un **bus mémoire**.

Certains dispositifs sont connectés au système via un **bus d'E/S général**.

- **Bus** : dispositif permettant de transmettre des données entre le(s) processeur(s), la mémoire vive et les périphériques d'E/S.
- **Bus d'E/S** : dispositif qui relie le(s) processeur(s) aux périphériques d'E/S.

Pourquoi avons-nous besoin d'une telle structure hiérarchique ?

- **Physique** : plus un bus est rapide, plus il doit être court et moins il y a de place pour connecter des périphériques.
- **Coût** : un bus à haute performance coûte cher.

Un périphérique canonique

Composants fondamentaux :

- L'**interface matérielle** permet au logiciel du système de contrôler son fonctionnement.
- La **structure interne** dépend du périphérique.

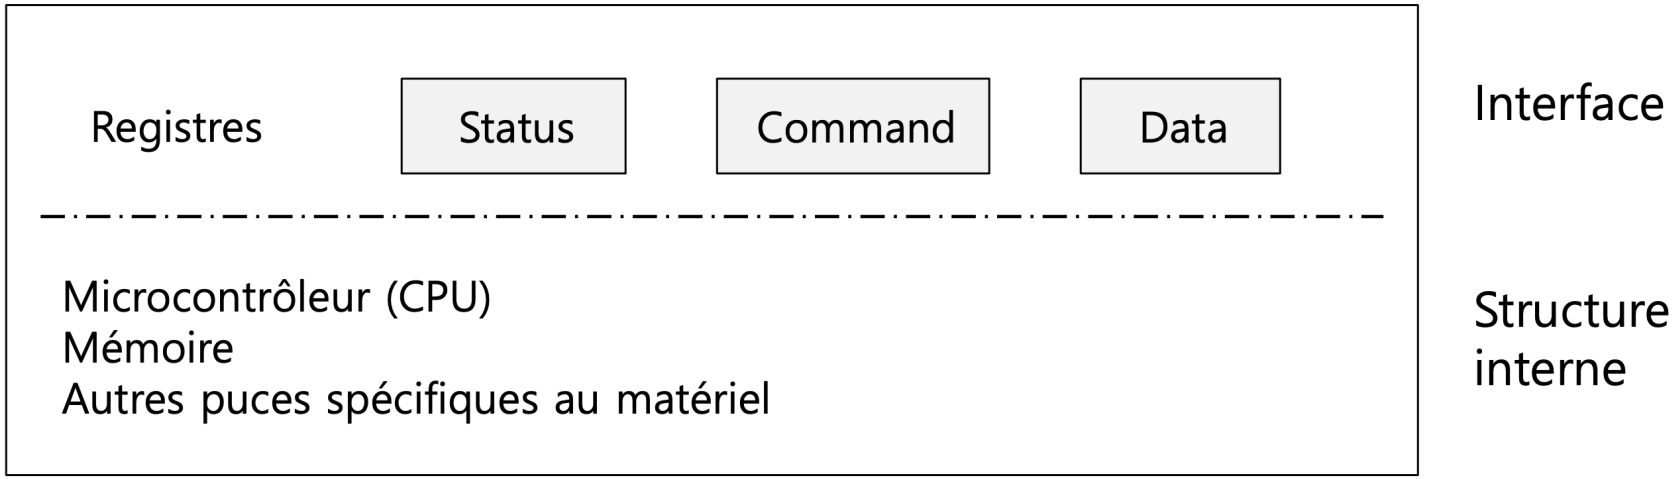

Périphérique canonique

Interface matérielle du périphérique canonique

Composée de 3 registres :

- `status` : pour lire l'état actuel du périphérique (ex : *BUSY*).
- `command` : pour demander à l'appareil d'effectuer une certaine tâche.
- `data` : pour transmettre des données au périphérique ou récupérer des données.

En lisant et en écrivant dans ces registres, le système d'exploitation peut contrôler le périphérique.

Exemple d'interaction du système d'exploitation avec le périphérique

```
while (STATUS == BUSY)
    ; // attendre que le périphérique ne soit pas occupé
Write data to DATA register
Write command to COMMAND register
    (starts the device and executes the command)
while (STATUS == BUSY)
    ; // attendre que le périphérique ait traité votre demande
```

Polling (attente active)

Le système d'exploitation **attend que l'appareil soit prêt** en lisant plusieurs fois le registre `status`.

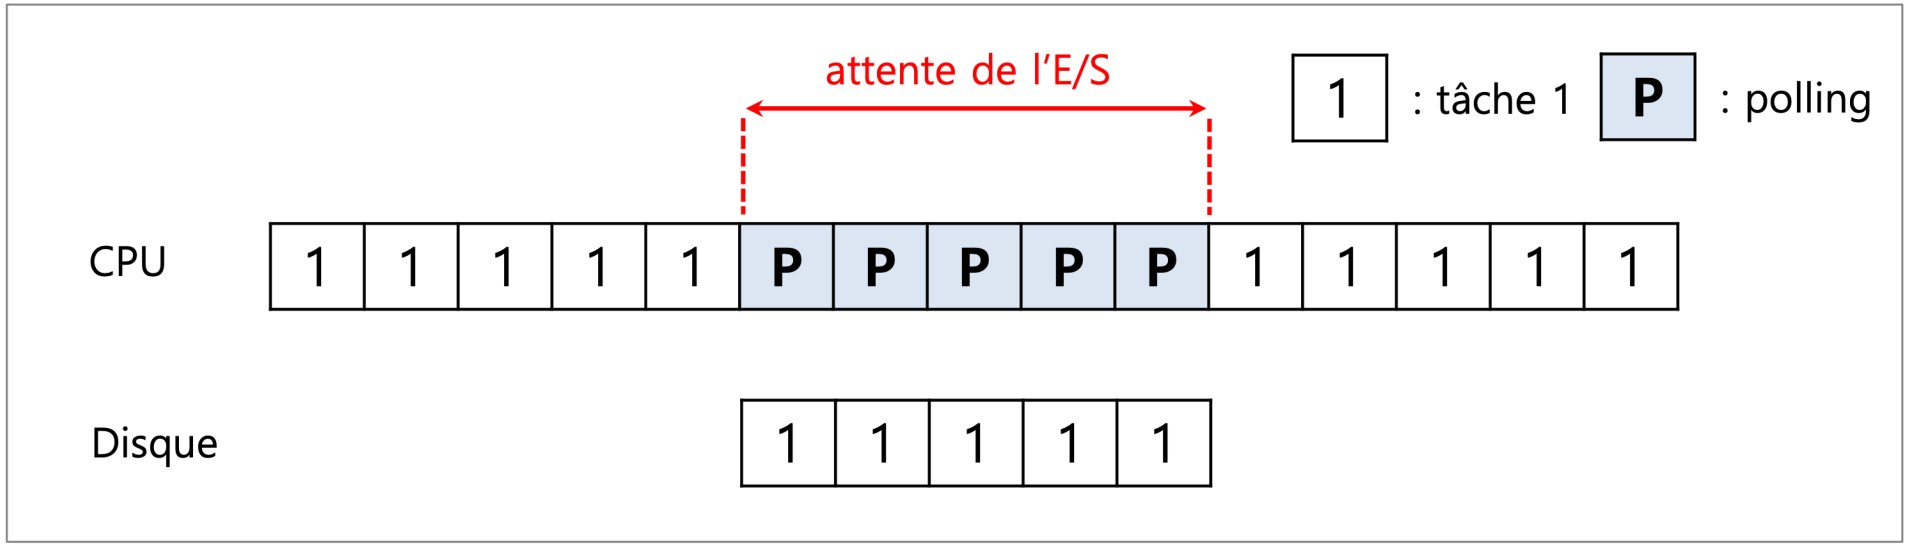

→ Cette méthode est simple mais l'attente active fait perdre temps processeur.

Interruptions

Mettre en **attente le processus** qui demande une E/S et exécuter un autre processus. Lorsque le périphérique a terminé, **réveiller** le processus qui attend l'E/S par une **interruption**.

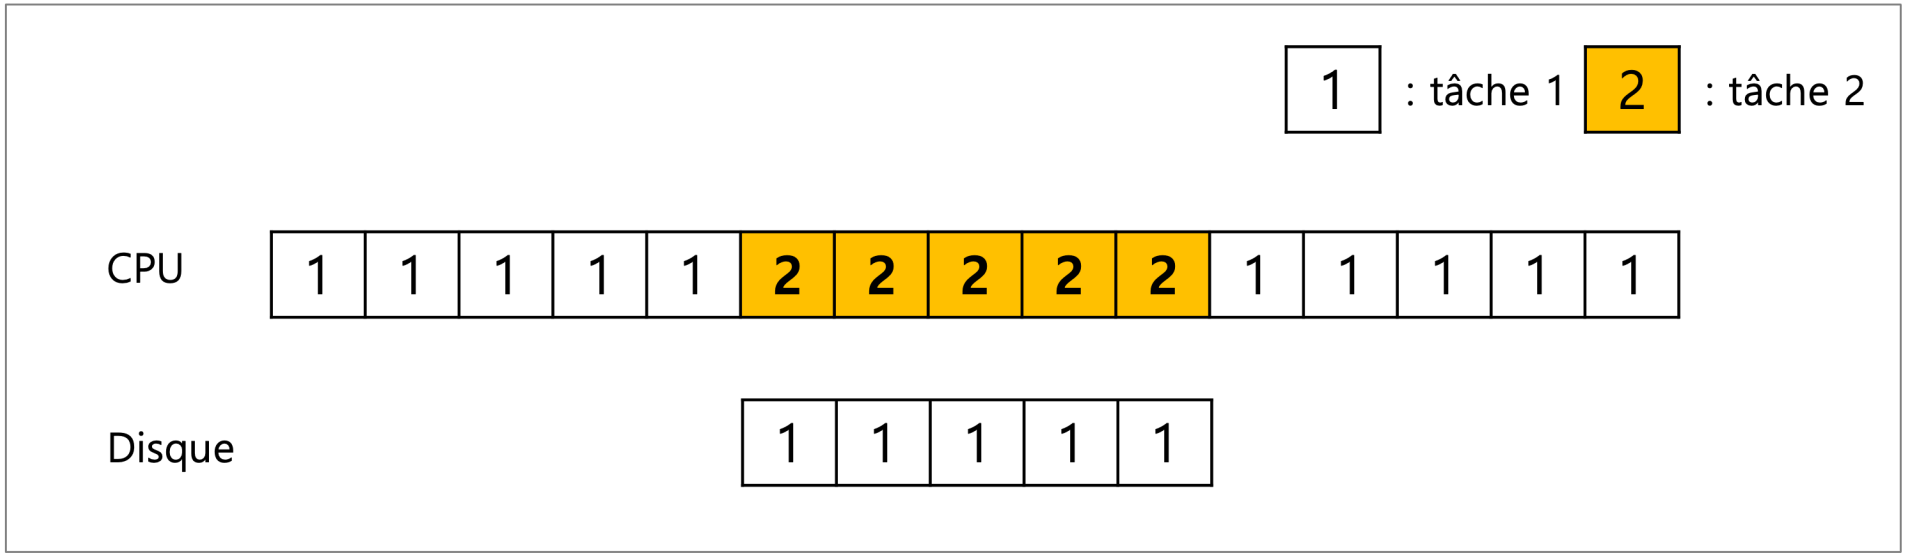

→ Le processeur et le disque sont utilisés de manière efficiente.

Faut-il privilégier le polling ou les interruptions ?

⚠️ **Les interruptions ne sont pas toujours la meilleure solution.**

→ Si le périphérique termine son opération très rapidement, l'interruption "ralentira" le système. En effet, la commutation de contexte est coûteuse

Si un périphérique est **rapide** → privilégier le **polling**.
Si un périphérique est **lent** → privilégier les **interruptions**.

Surcharge du processeur lors du transfert de données

Problème : le processeur passe beaucoup de temps à **copier les données de la mémoire vers le périphérique**.

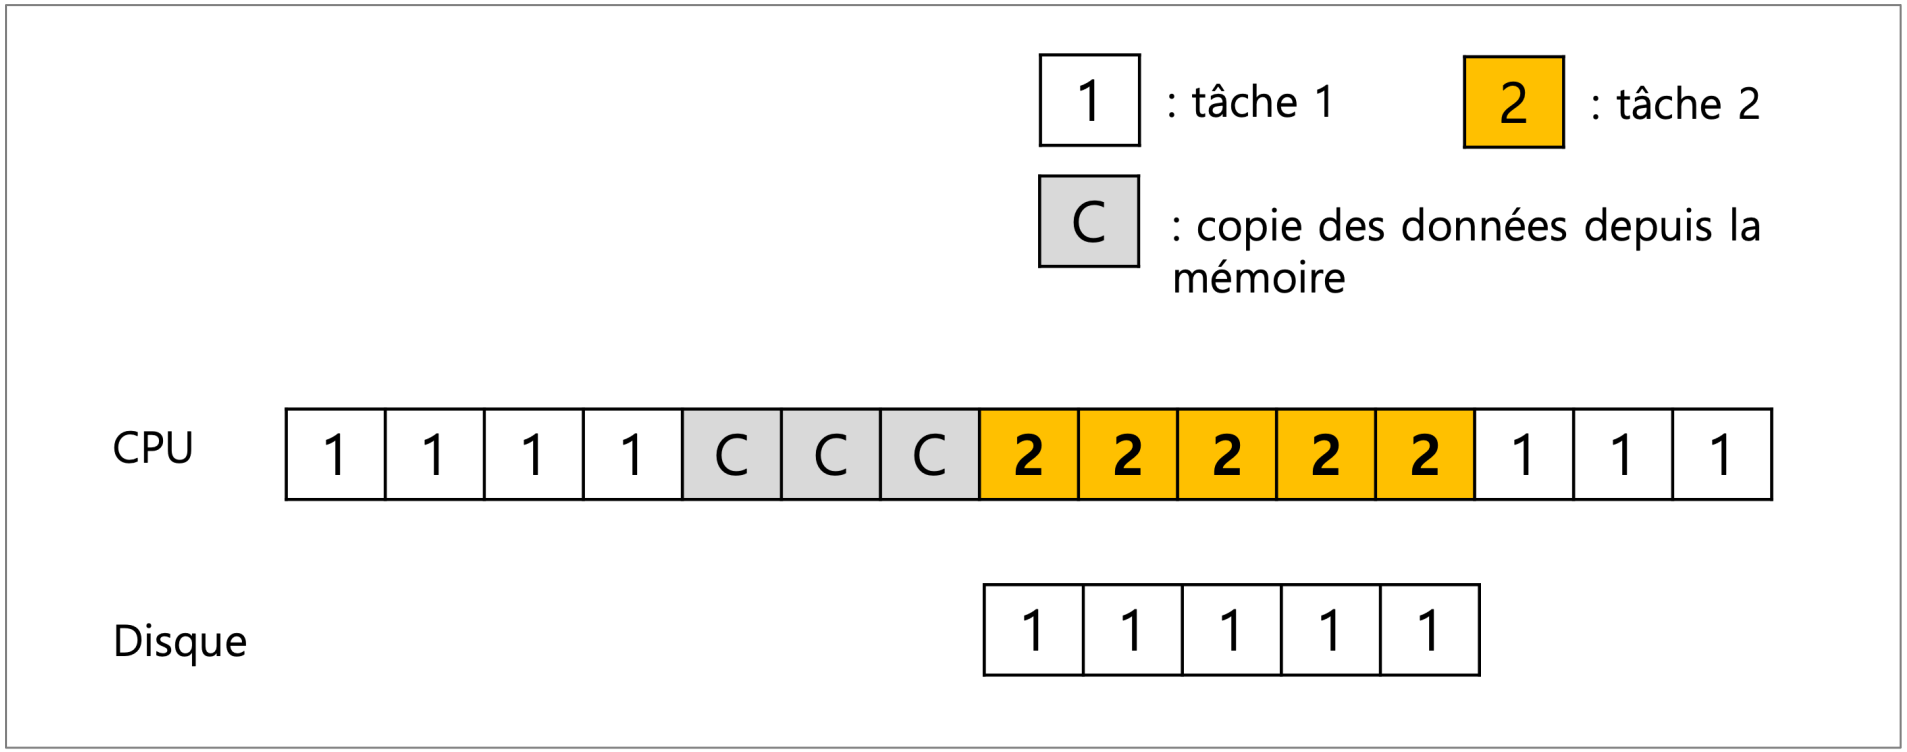

Direct memory access (DMA)

- Le **DMA engine** copie les données en sachant où se trouvent les données en mémoire et quelle quantité copier.
- Une fois la copie terminée, le DMA engine déclenche une **interruption** pour indiquer à l'OS que le transfert est complet.

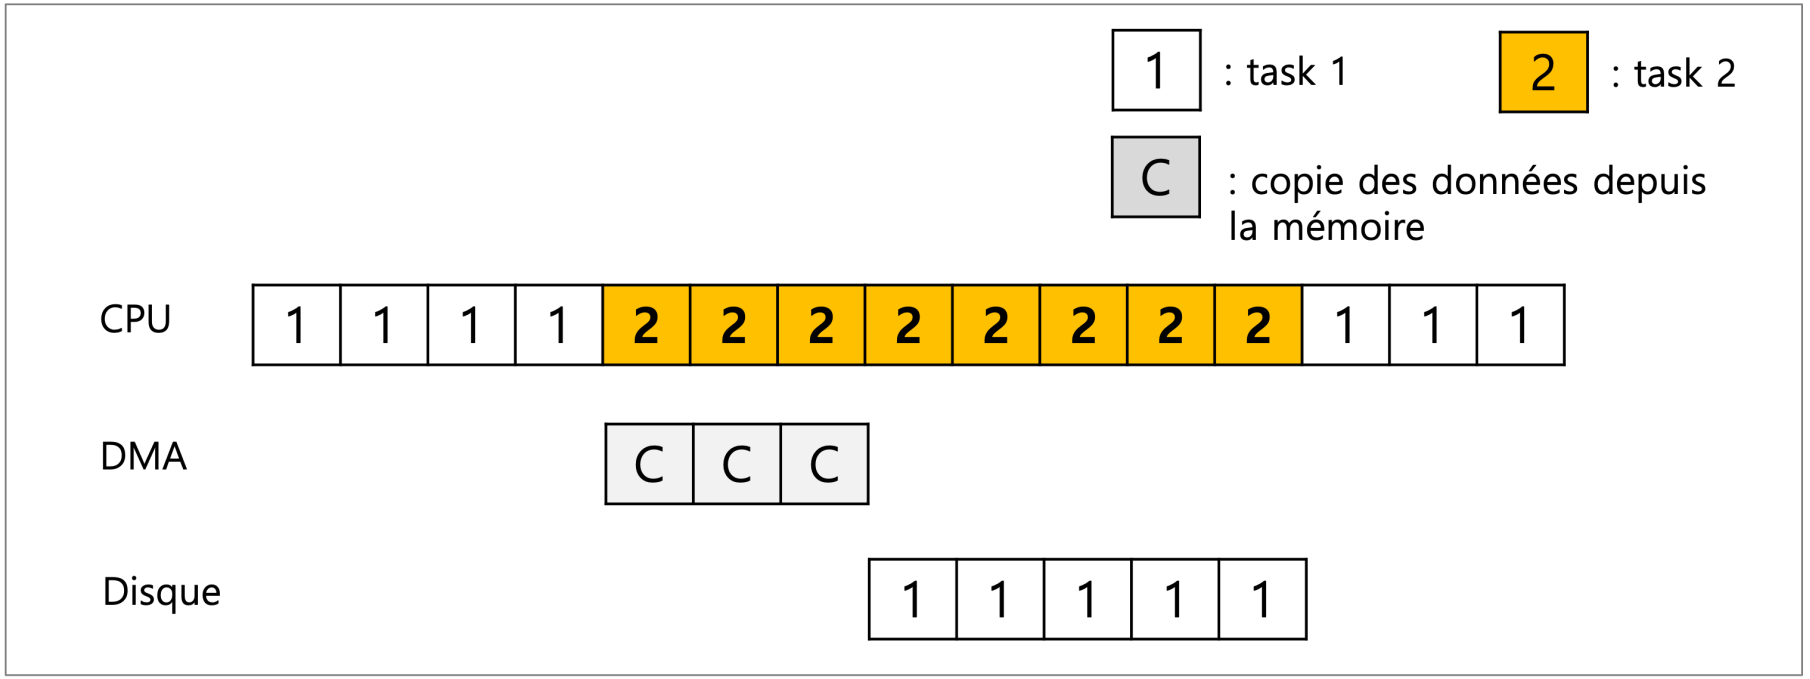

Comment le système d'exploitation communique avec un périphérique ?

- **Instructions d'E/S** : permettent au système d'exploitation d'envoyer des données à des registres de périphériques spécifiques.
  ex : instructions `in` *et* `out` *sur x86.*
- **Memory-mapped I/O** : les registres de périphériques sont disponibles comme s'il s'agissait d'emplacements mémoires.

  Pour accéder à un registre particulier, l'OS lit ou écrit à une adresse mémoire particulière ; le matériel achemine la lecture ou l'écriture vers le périphérique plutôt que vers la mémoire principale.

Pilotes de périphériques

Comment faire en sorte que le système d'exploitation n'ait pas à se soucier des spécificités des périphériques avec lesquels il interagit ?

Ex : on souhaite un système de fichiers qui fonctionne sur les disques SCSI, les disques IDE, les clés USB, etc.

→ *Solution* : l'**abstraction**.

Pilote de périphérique (*device drivers*) : un morceau de logiciel qui encapsule les spécificités nécessaires à l'interaction avec un périphérique donné.

L'abstraction du système de fichiers

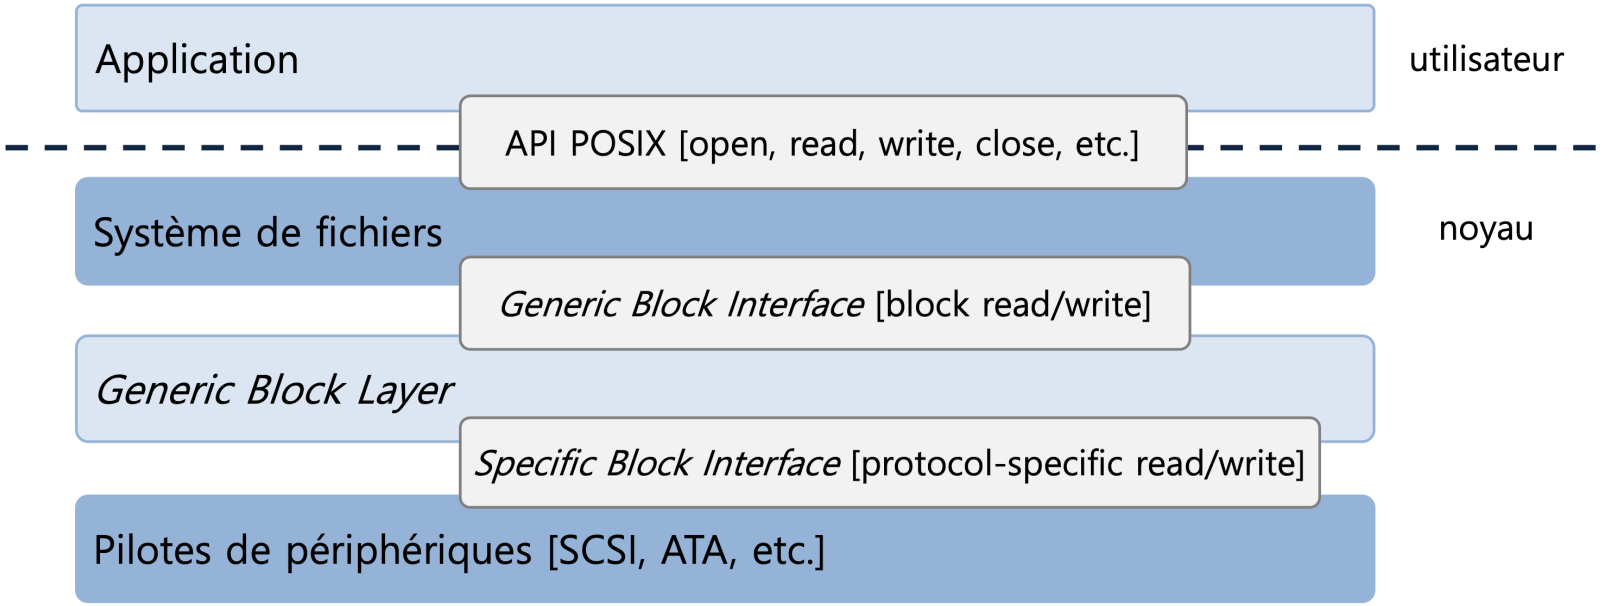

Un système de fichiers n'est pas conscient des spécificités de la classe de disque qu'il utilise ; il émet simplement des demandes de lecture et d'écriture de blocs à la couche générique, qui les achemine vers le pilote de périphérique approprié, qui gère les détails de traitement de la requête.

Limites de l'abstraction

- Si un périphérique possède de nombreuses fonctionnalités spécifiques, celles-ci ne seront pas disponibles dans l'interface générique.
- Plus de **70 % du code du système d'exploitation se trouve dans les pilotes de périphériques**. Ces pilotes sont nécessaires pour supporter tous les périphériques qui peuvent être branchés sur le système.

  Ils sont les principaux responsables des pannes du noyau.

Disques durs

Depuis des décennies, les disques durs constituent la principale forme de stockage de **données persistantes** dans les systèmes informatiques.

Le disque se compose d'un grand nombre de **secteurs** (blocs de **512 octets**).

- On peut considérer un disque avec `n` secteurs comme un tableau de secteurs allant de `0` à `n-1`.
- L'écriture d'un bloc de 512 octets est garantie comme **atomique**.

Composants d'un disque dur

- **Plateau**
  - Surface circulaire en aluminium recouverte d'une fine couche magnétique.
  - Les données sont stockées de manière persistante en induisant des changements magnétiques.
  - Chaque plateau a deux faces, chacune étant appelée surface.
- **Axe**
  - Relié à un moteur qui fait tourner les plateaux.
  - La vitesse de rotation est mesurée en RPM (rotations par minute).
    Valeurs modernes typiques : 7 200 RPM à 15 000 RPM.
    Par exemple, 10000 RPM : une rotation dure environ 6 ms.

- **Pistes**
  - Cercles concentriques de **secteurs**.
  - Les données sont encodées sur chaque surface d'une piste.
  - Une seule surface contient des milliers de pistes.

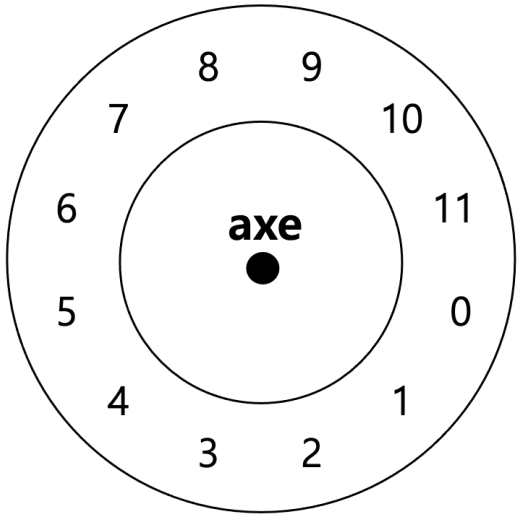

Un disque avec une unique piste (12 secteurs)

- **Tête de lecture/écriture**
  - Le processus de lecture et d'écriture est accompli par la tête de disque.
  - Attachée à un bras qui se déplace sur la surface.
  - Une tête par surface.

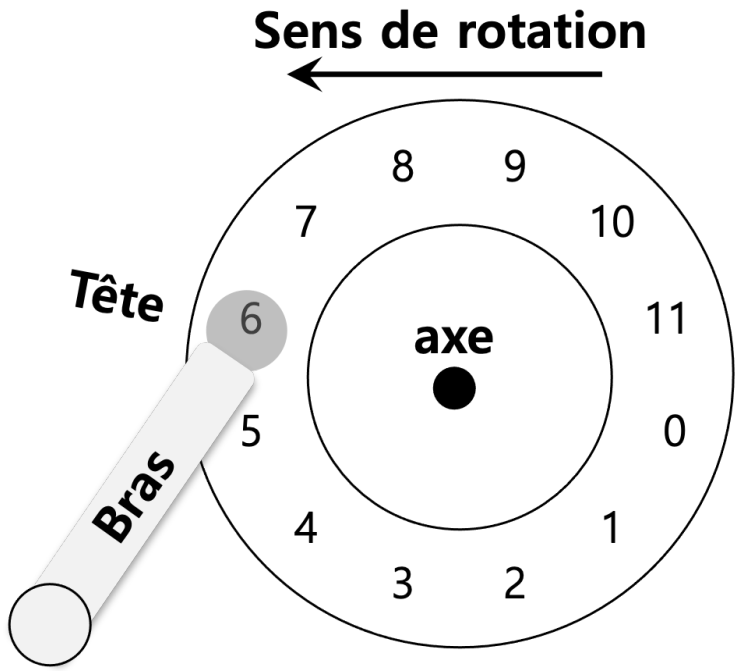

Une unique piste et une tête

Structure d'un disque dur

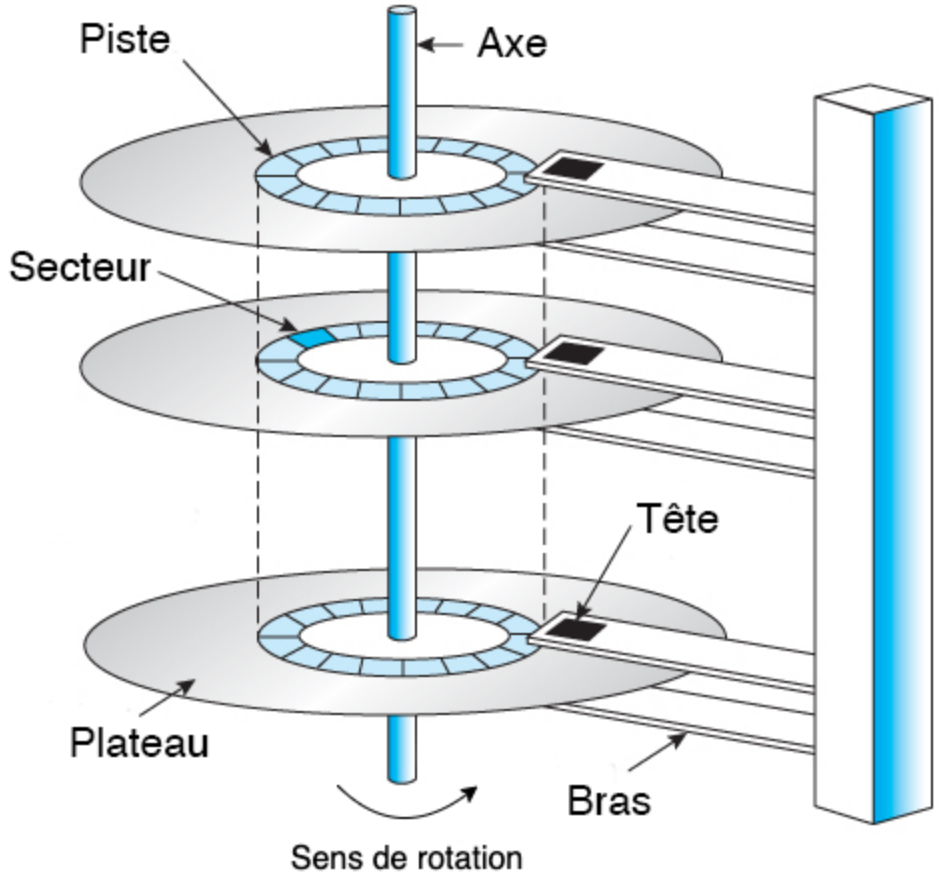

Délai de rotation

C'est le temps de rotation jusqu'au secteur souhaité.

Exemple : le délai de rotation complet est `R` et nous commençons au secteur `6`.

- Lecture du secteur `0` :
  - délai de rotation = `R / 2`
- Lecture du secteur `5` :
  - délai de rotation = `R-1` (cas le plus défavorable)

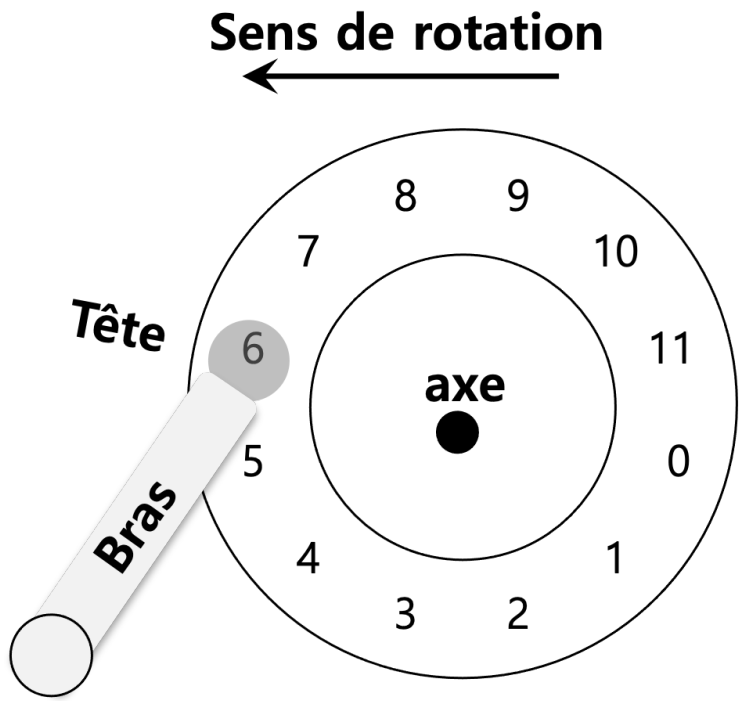

Une seule piste et un bras

Seek time

Seek : opération de déplacement de la tête sur la piste correcte.

→ une des opérations les plus coûteuses du disque (plusieurs ms).

Seek time : temps nécessaire pour déplacer la tête sur la piste contenant le secteur souhaité.

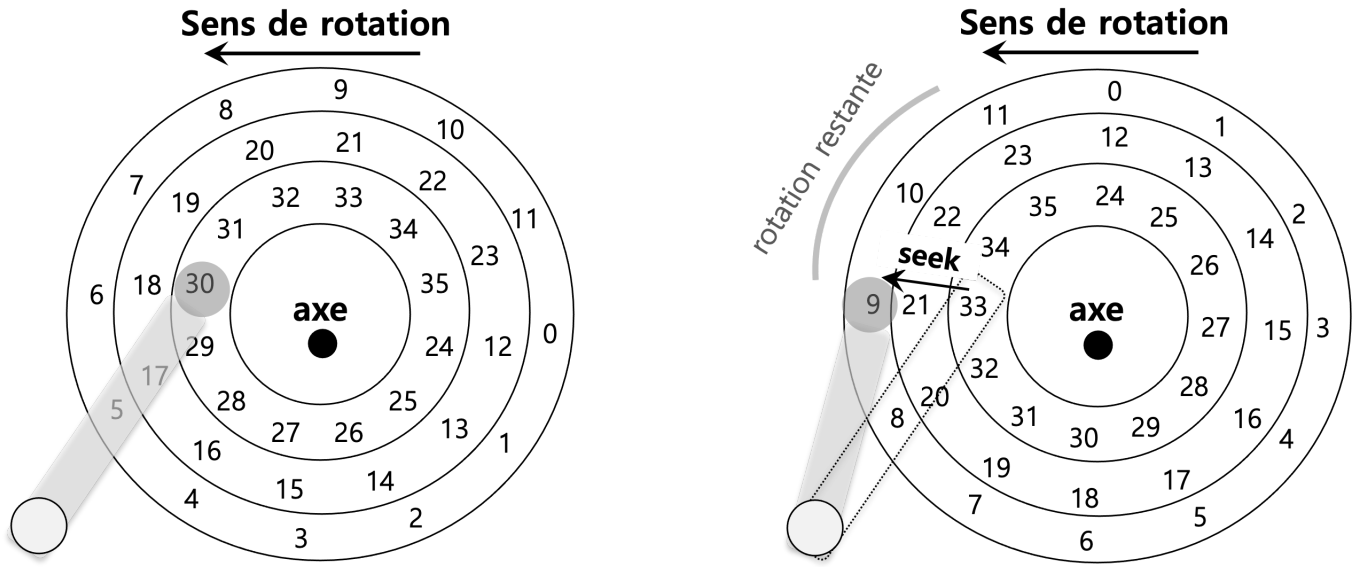

Trois pistes plus une tête
(à droite : avec seek, lecture du secteur 11)

Étapes d'une lecture/écriture sur le disque

1. Seek
2. Attente du délai de rotation
3. Transfère des données : les données sont lues ou écrites sur la surface.

Cache

- Conserve les données lues ou à écrire sur le disque
- Permet au disque de répondre rapidement aux requêtes.
- Petite quantité de mémoire (généralement autour de 8 ou 16 Mo).

Gestion des écritures

- **Writeback** : accuse réception d'une écriture lorsqu'il a placé les **données dans le cache** → risque de perte de données.
- **Write through** : accuse réception d'une écriture après qu'elle a été **réellement écrite sur le disque**.

Mesurer la performance d'une E/S sur le disque

Durée de l'E/S : $T_{E/S} = T_{seek} + T_{rotation} + T_{transfert}$

Débit de l'E/S : $D_{E/S} = \frac{Taille_{transfert}}{T_{E/S}}$

Accès aléatoire contre séquentiel

On considère deux types de disques durs.

	Cheetah 15K.5	Barracuda
Capacité	300 Go	1 To
RPM	15,000	7,200
Seek moyen	4 ms	9 ms
Max Transfert	125 Mo/s	105 Mo/s
Plateaux	4	4
Cache	16 Mo	16/32 Mo
Connectique	SCSI	SATA

Charges de travail

- **Lecture aléatoire** : lecture de 4 Ko vers des emplacements aléatoires du disque.
- **Lecture séquentielle** : lecture consécutive de 100 Mo sur le disque.

Accès aléatoire contre séquentiel : résultats

		Cheetah 15K.5	Barracuda
T_{seek}		4 ms	9 ms
$T_{rotation}$		2 ms	4.2 ms
Aléatoire	$T_{transfert}$	30 microsecs	38 microsecs
	$T_{E/S}$	6 ms	13.2 ms
	$D_{E/S}$	0.66 Mo/s	0.31 Mo/s
Séquentielle	$T_{transfer}$	800 ms	950 ms
	$T_{I/O}$	806 ms	963.2 ms
	$D_{E/S}$	125 Mo/s	105 Mo/s

→ **Il y a écart de performances très important entre la lecture aléatoire et la lecture sequentielle**. Il en serait de même pour l'écriture.

Ordonnancement des requêtes d'E/S sur le disque

L'**ordonnanceur du disque** décide de l'ordre de traitement des requêtes d'E/S.

- **SSTF (Shortest Seek Time First)**
  - Ordonne la file d'attente des requête d'E/S par piste.
  - Choisit les demandes sur la piste la plus proche pour les traiter en premier.
- **SCAN (Elevator)**
  - Balaye le disque d'une extrémité à l'autre.
  - Si une demande concerne un secteur sur une piste qui a déjà été desservie lors de ce balayage du disque, elle est mise en file d'attente jusqu'au balayage suivant.
  - F-SCAN et C-SCAN sont des variantes.

Fusion des requêtes d'E/S

Réduit le nombre de requêtes envoyées au disque et diminue la charge de travail.

Par exemple, pour lire les blocs `33`, puis `8`, puis `34` → l'ordonnanceur fusionne les requêtes pour les blocs `33` et `34` en une seule requête.

Pour aller plus loin

- Case study: A simple IDE disk driver
- SSD : une nouvelle forme de stockage persistent de plus en plus présente.